PREDIÇÃO DE APROVAÇÃO DE PEDIDOS DE CARTÃO DE CRÉDITO UTILIZANDO APRENDIZADO DE MÁQUINA



GRUPO 9
JOSUELITO BALBINO DA SILVA
JOYCE KELLY SIMPLICIO DA LAGE
TIAGO DE ALMEIDA SILVA

ETAPAS DO PROJETO

1) Limpeza e o pré-processamento da base de dados;
2) Analise e exploração estatística dos atributos;
3) Parâmetros utilizados para o modelo;
4) Modelo de classificação escolhido;
5) Métricas de desempenho do modelo;
6) Conclusão e Interpretação do modelo.



1 - LIMPEZA E O PRÉ-PROCESSAMENTO DA BASE DE DADOS

- Validação da estrutura, colunas obrigatórias e valores ausentes.
- Padronização e validação dos códigos de STATUS.
- Verificação e eliminação de possíveis duplicidades ID + mês.
- Verificação da continuidade temporal do histórico dos clientes.
- Seleção dos 12 meses mais recentes disponíveis por cliente.
- Tratamento de duplicidades na base cadastral, mantendo uma linha por cliente.
- Integração da base cadastral com o TARGET por meio de merge 1:1.
- Validação da unicidade, exposição temporal e distribuição do TARGET na base final.

2 - ANALISE E EXPLORAÇÃO ESTATÍSTICA DOS ATRIBUTOS

Principais achados da Análise Exploratória

- Base final com **32.617 clientes**, IDs únicos e TARGET sem valores ausentes.
- **Forte desequilíbrio entre bons e maus pagadores**, exigindo atenção à classe minoritária.
- Variáveis numéricas apresentam **assimetria e outliers**, porém sem evidências suficientes para exclusão automática.
- **Correlação individual com o TARGET muito baixa** (≈ -0,04 a 0,03).
- Forte correlação entre atributos relacionados à **estrutura familiar e renda**.
- IS_RETIRED e EMPLOYMENT_SPECIAL_VALUE apresentam **redundância quase perfeita (ρ ≈ 1,00)**.
- Identificados **9.264 perfis cadastrais,** sendo **6.190 idênticos** e desses identificamos **1.136 com TARGET (bons e maus pagadores) divergentes**.
- Resultado indica que **atributos cadastrais isolados não explicam a inadimplência**.
- Variáveis derivadas do histórico de crédito foram removidas para evitar **vazamento de informação**.

3 - PARÂMETROS UTILIZADOS PARA O MODELO

- **Clientes com histórico mínimo de 12 meses**, permitindo a aplicação da **Vintage Analysis** para acompanhar a evolução do comportamento de pagamento ao longo do tempo;

```
Clientes com menos de 12 meses: 12274
Percentual com menos de 12 meses: 30.12%
Clientes com 12 meses: 28478
```

MESES_OBSERVADOS	quantidade_clientes	proporcao
1 a 3 meses	2259	0.0554
4 a 6 meses	3607	0.0885
7 a 9 meses	4006	0.0983
10 a 11 meses	2402	0.0589
12 meses	28478	0.6988

3 - PARÂMETROS UTILIZADOS PARA O MODELO

- **Clientes com 30 ou mais dias de atraso** (Status 1 a 5) classificados como **maus pagadores**, considerando a ocorrência de inadimplência no período analisado;

```
Status de mau pagador: ['1', '2', '3', '4', '5']
```

3 - PARÂMETROS UTILIZADOS PARA O MODELO

- **Exclusão dos clientes classificados como Status X**, uma vez que essa categoria não apresenta informação suficiente sobre o comportamento de crédito, impossibilitando sua classificação de forma confiável entre bons e maus pagadores.

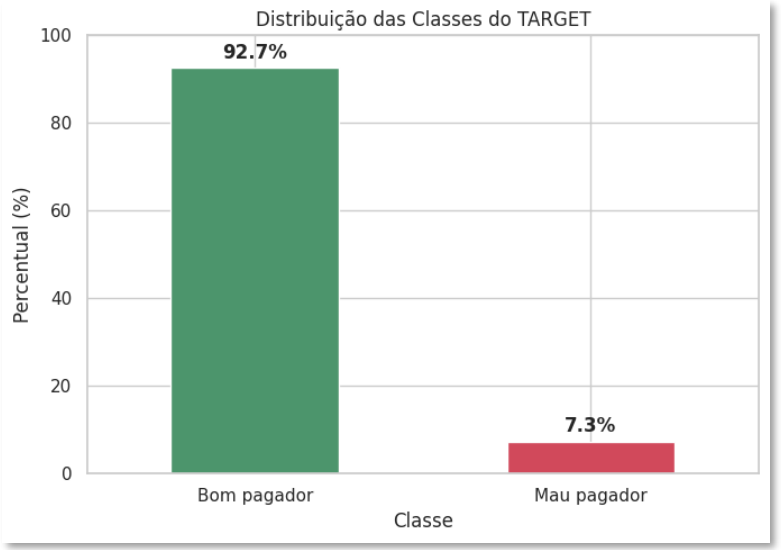
```
Clientes antes da exclusão: 45985
Clientes somente com STATUS X: 5233
Percentual somente com STATUS X: 11.38%
```

```
Clientes excluídos: 5233
Clientes válidos após a exclusão: 40752
```

```
Clientes com TARGET válido: 40752
Clientes na base final: 32617
Linhas na base final: 32617
IDs duplicados: 0

Distribuição absoluta do TARGET:
TARGET
0    30219
1     2398
Name: count, dtype: int64

Distribuição percentual do TARGET:
TARGET
0   92.6500
1    7.3500
Name: proportion, dtype: float64
```



4 - MODELO DE CLASSIFICAÇÃO ESCOLHIDO

Escolha do Modelo

- Testamos 6 modelos diferentes: Regressão Logística, Random Forest, Gradient Boosting, Decision Tree, Extra Trees e XGBoost. Sendo que o Random Forest apresentou os melhores resultados.

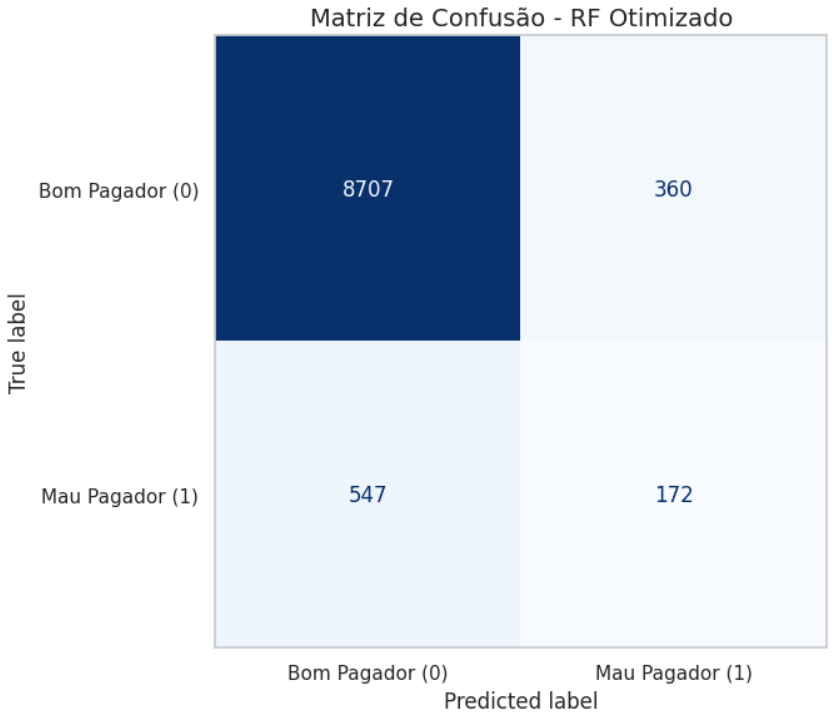
Validação cruzada dos três melhores modelos

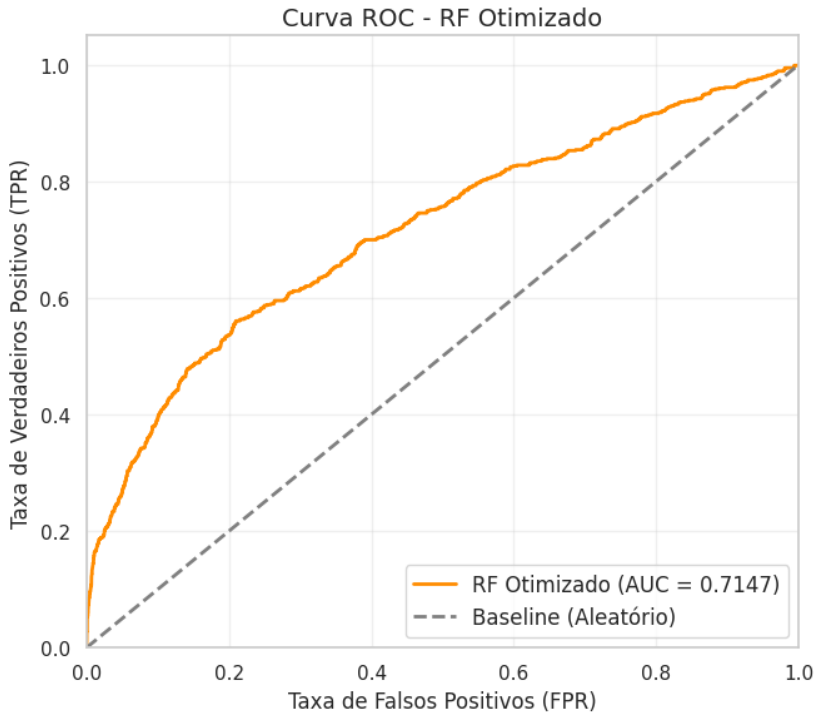
```
=== Resultados da Validação Cruzada ===
```

	Modelo	F1-Score (Média)	Desvio Padrão	Scores Individuais
0	Random Forest	0.9378	0.0024	[0.9387, 0.9416, 0.9383, 0.9345, 0.9359]
1	Extra Trees	0.9224	0.0023	[0.9231, 0.9208, 0.9219, 0.9265, 0.9197]
2	XGBoost	0.8986	0.0042	[0.8979, 0.8914, 0.8987, 0.9039, 0.9014]

5 – CONCLUSÃO E INTERPRETAÇÃO DO MODELO

O modelo Random Forest Otimizado demonstrou alta capacidade de identificação de bons pagadores ao classificar corretamente 8.707 casos (com apenas 360 falsos positivos), enquanto capturou 172 maus pagadores de um total de 719, **refletindo o desafio típico do desbalanceamento de classes na base de dados**. Complementarmente, a Curva ROC atingiu uma métrica AUC de 0,7147, confirmando um desempenho superior ao modelo aleatório (baseline) e atestando uma capacidade discriminatória satisfatória para a separação entre maus e bons pagadores no contexto de risco de crédito.







OBRIGADO

INTEGRANTES DO GRUPO 9

JOSUELITO BALBINO DA SILVA
JOSUELITO.SILVA@BB.COM.BR

JOYCE KELLY SIMPLICIO DA LAGE
JKSLAGE@HOTMAIL.COM

TIAGO DE ALMEIDA SILVA
TIAGO.SILVA.330@BB.COM.BR